Modelos multimodales explicados fácil

Guía para quien nunca ha trabajado con modelos multimodales: cada idea va primero en palabras, luego con un ejemplo con números pequeños, y solo al final con la fórmula. Todo el recorrido usa el mismo ejemplo: adivinar los géneros de una película a partir de su póster y su sinopsis (el dataset MM-IMDB del proyecto).

1. ¿Qué es un modelo multimodal?

Un modelo multimodal es un modelo que toma una decisión usando información de dos o más tipos distintos a la vez. A cada tipo de información se le llama **modalidad**.

Ejemplos de modalidades: una imagen, un texto, un audio, una señal del corazón, una tabla de datos.

Ejemplo de la vida diaria. Cuando eliges una película en una plataforma, miras dos cosas: el póster (imagen) y la descripción (texto). Con las dos juntas adivinas mejor de qué trata que con una sola. Un modelo multimodal intenta hacer lo mismo de forma automática.

Nuestro caso. Tomamos una película inventada, *La casa del silencio*:

Lo que el modelo recibe	Lo que el modelo debe responder
El póster: una casa oscura con una ventana iluminada	Sus géneros: Terror y Drama
La sinopsis: "Una familia se muda a una casa antigua donde la hija menor habla con un amigo invisible"	

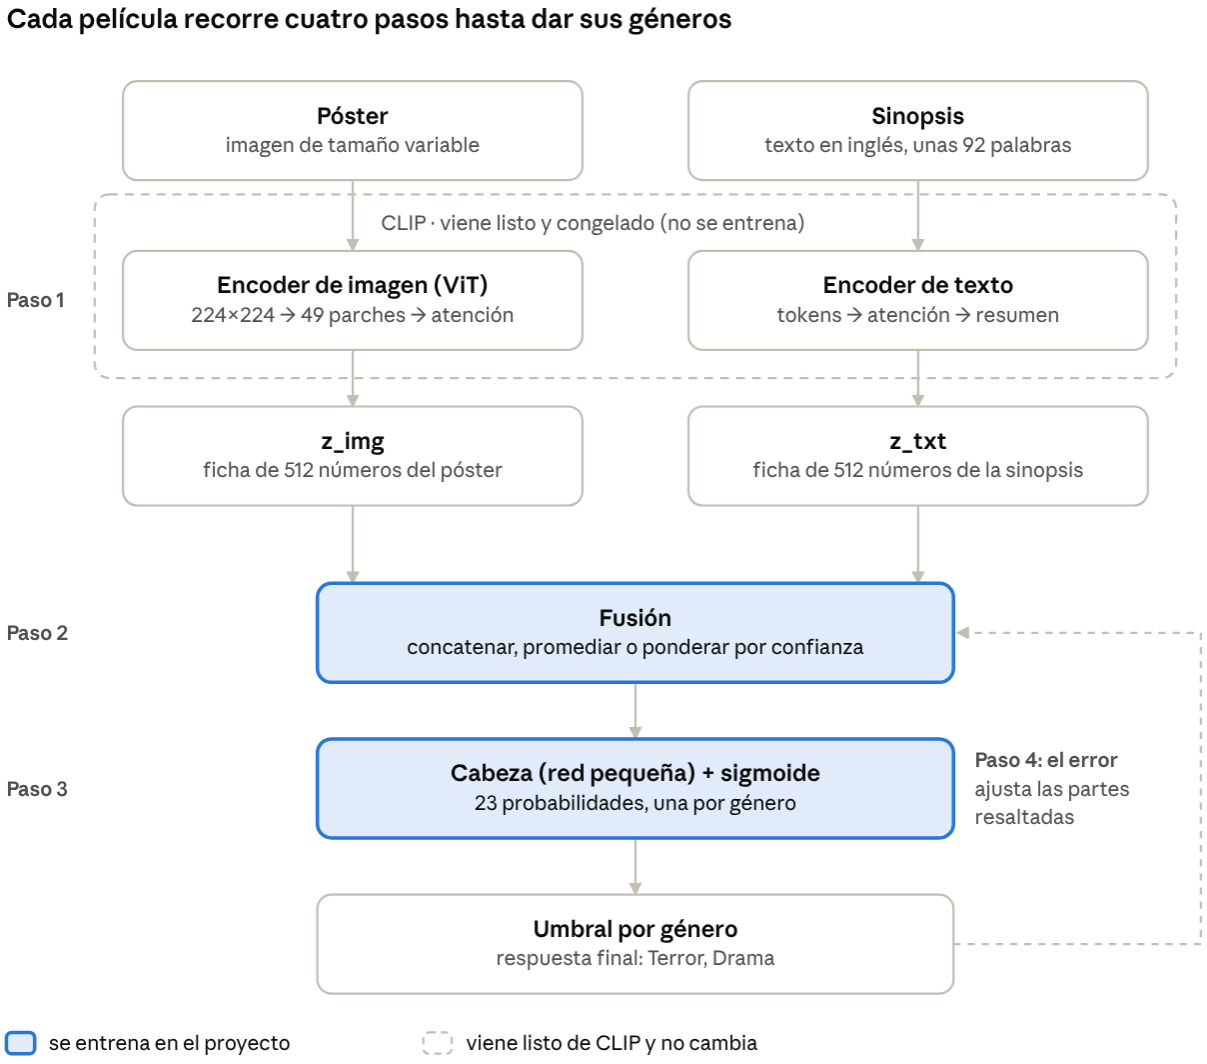
Una película puede tener varios géneros a la vez. Por eso la respuesta no es "un género" sino una lista de sí o no para cada uno de los 23 géneros del dataset.

¿Por qué no basta con una sola modalidad? Porque cada una ve cosas que la otra no:

- La sinopsis dice "amigo invisible", pero no dice si el tono es de miedo o de ternura.
- El póster oscuro sugiere miedo, pero no dice que hay una familia ni de qué trata.
- Juntas, apuntan con claridad a Terror.

La promesa de un modelo multimodal es exactamente esa: **dos fuentes juntas deberían acertar más que cualquiera sola.** El proyecto estudia por qué muchas veces esa promesa no se cumple.

2. De un vistazo



recorrido de una película · del póster y la sinopsis a los géneros

Solo se entrenan la fusión y la cabeza (resaltadas); CLIP convierte póster y sinopsis en números y no cambia. Cada caja corresponde a una sección de esta guía: el paso 1 es la sección 4, el paso 2 la 5, el paso 3 la 6 y el paso 4 la 7.

3. Diccionario de símbolos

Esta guía usa muy pocos símbolos, y todos están aquí. Si una fórmula te confunde, vuelve a esta tabla.

Símbolo	Se lee	Qué significa	En el ejemplo
imagen	"imagen"	El póster tal como viene (píxeles)	La foto de la casa oscura

Símbolo	Se lee	Qué significa	En el ejemplo
texto	"texto"	La sinopsis tal como viene (palabras)	"Una familia se muda..."
z_img	"zeta imagen"	El póster convertido en una lista de números	[0.9, 0.1, 0.3, ...]
z_txt	"zeta texto"	La sinopsis convertida en una lista de números	[0.2, 0.8, 0.5, ...]
p	"pe"	Una probabilidad: un número entre 0 y 1	p(Terror) = 0.85 significa 85%
y	"ye"	La respuesta correcta: 1 si la película tiene ese género, 0 si no	y(Terror) = 1, y(Comedia) = 0
w	"doble ve"	Un peso: cuánto cuenta algo en un promedio	w_img = 0.3 significa que la imagen pesa 30%
σ	"sigma"	La función sigmoide: convierte cualquier número en una probabilidad	σ(2) = 0.88
log	"logaritmo"	Logaritmo natural; solo se usa para medir errores	log(0.9) = −0.105

Una convención: cuando algo lleva "_img" es de la imagen, y cuando lleva "_txt" es del texto. Por ejemplo, p_img(Terror) es la probabilidad de Terror que da el modelo que solo mira el póster.

4. Paso 1 — Convertir cada modalidad en números

Un modelo solo sabe hacer cuentas, así que antes de nada hay que convertir el póster y la sinopsis en listas de números del mismo tamaño. Esa lista se llama **embedding** (o vector), y el programa que la produce se llama **encoder**.

4.1 ¿Qué es un embedding?

Un embedding es como una ficha de descripción con muchas casillas, donde cada casilla mide algo. Un ejemplo de juguete con solo 3 casillas:

	¿Qué tan oscuro / inquietante?	¿Qué tan alegre?	¿Qué tan romántico?
Póster de *La casa del silencio*	0.9	0.1	0.3
Póster de una comedia familiar	0.1	0.9	0.2
Póster de otra película de terror	0.8	0.2	0.1

Los dos pósters de terror tienen fichas parecidas y el de comedia es muy distinto. **Esa es la propiedad clave: cosas parecidas quedan con números parecidos.**

En la realidad hay dos diferencias con este juguete: la ficha tiene 512 casillas, no 3, y nadie decide qué mide cada casilla. El encoder las aprende solo durante su entrenamiento. Por eso no se puede decir "la casilla 37 mide la oscuridad", pero sí se cumple que pósters parecidos dan fichas parecidas.

4.2 El encoder de imágenes, paso a paso

1. **Achicar el póster** a 224 × 224 píxeles, porque el encoder siempre espera ese tamaño.
2. **Ajustar la escala de los colores** (normalizar). Cada píxel tiene tres valores (rojo, verde, azul). Se les resta un promedio y se dividen por una desviación, igual que cuando calculas un puntaje z en estadística. Se usan los mismos valores que se usaron al entrenar el encoder, para que reciba los números en la escala que conoce.
3. **Cortar la imagen en cuadritos** (parches) de 32 × 32 píxeles, como baldosas. Salen 7 × 7 = 49 cuadritos.
4. **Hacer que los cuadritos se "miren" entre sí** (atención). Cada cuadrito actualiza su descripción mirando a los demás. El cuadrito de la ventana iluminada, al ver que el resto de la casa está a oscuras, pasa a significar "algo inquietante pasa adentro".
5. **Resumir todo en una ficha de 512 números:** ese es z_img.

El modelo que hace los pasos 3 a 5 se llama **ViT** (Vision Transformer).

4.3 El encoder de texto, paso a paso

1. **Cortar el texto en pedacitos** (tokens). Las palabras comunes son un pedacito; las raras se parten: "amigo" → [amigo], "invisiblemente" → [invisible] [mente].
2. **Cambiar cada pedacito por su número** en un diccionario de unos 49 mil pedacitos.
3. **Cambiar cada número por su propia ficha** de números, sacada de una tabla que el encoder ya aprendió.

4. **Hacer que las palabras se "miren" entre sí** (atención). "Amigo", al ver "invisible" y "casa antigua" cerca, pasa a significar algo inquietante y no algo tierno.
5. **Resumir todo en una ficha de 512 números:** ese es z_txt.

Un límite importante: este encoder solo lee unos 77 pedacitos (≈ 55 palabras). Si la sinopsis es más larga, se parte en trozos, se saca una ficha por trozo y se promedian.

4.4 ¿Qué es CLIP y por qué lo usamos?

CLIP es un par de encoders (uno de imágenes y uno de textos) que OpenAI entrenó con 400 millones de fotos de internet junto con su descripción. El entrenamiento fue un juego de emparejar: dada una foto, encontrar cuál de muchos textos es el suyo.

Ejemplo del juego:

	"un perro en la playa"	"una pizza"	"un edificio de noche"
Foto de perro	✅ debe parecerse	❌	❌
Foto de pizza	❌	✅	❌
Foto de edificio	❌	❌	✅

Para ganar ese juego, CLIP aprendió a dar fichas parecidas a una foto y a su descripción. Gracias a eso, el póster de terror y la sinopsis de terror quedan con fichas parecidas aunque una sea imagen y la otra texto: **las dos modalidades quedan en el mismo "idioma" de números.**

4.5 Encoders congelados

No vamos a reentrenar CLIP: lo usamos tal como viene. A eso se le llama **congelar** el encoder. Ventaja: las fichas de las ≈26 mil películas se calculan **una sola vez**, se guardan en el disco, y todo el resto del proyecto trabaja con esas fichas. Entrenar sobre fichas guardadas tarda segundos o minutos, no días.

5. Paso 2 — Combinar las modalidades (fusión)

Ya tenemos dos fichas de números, z_img y z_txt. **Fusionar** es decidir cómo juntarlas para llegar a una sola respuesta. Hay tres formas principales, y la diferencia es en qué momento se juntan.

Para los ejemplos usamos fichas de juguete de 3 números:

- z_img = [0.9, 0.1, 0.3]
- z_txt = [0.2, 0.8, 0.5]

5.1 Fusión temprana: pegar las fichas

Se ponen las dos fichas una detrás de la otra (se **concatenan**) y una sola red decide con todo junto:

```
[0.9, 0.1, 0.3]  +  [0.2, 0.8, 0.5]   →   [0.9, 0.1, 0.3, 0.2, 0.8, 0.5]
    z_img               z_txt                  ficha combinada de 6 números
```

Luego, una red pequeña (un MLP) recibe los 6 números y da las probabilidades de cada género.

- **Ventaja:** es lo más simple y la red puede descubrir relaciones entre imagen y texto.
- **Problema:** nada obliga a la red a usar las dos mitades. Si con la mitad del texto ya acierta bastante, puede ignorar la mitad de la imagen. Por eso es nuestro modelo "ingenuo": ahí esperamos ver el problema que estudia el proyecto.

5.2 Fusión tardía: que cada una opine y luego promediar

Cada modalidad tiene su propia red, que da su propia respuesta. Al final se promedian las respuestas.

Ejemplo para el género Terror:

	Probabilidad de Terror
Red que solo mira el póster (p_img)	0.60
Red que solo mira la sinopsis (p_txt)	0.90
Promedio simple: (0.60 + 0.90) / 2	**0.75**

En fórmula, con pesos:

```
p_final = w_img × p_img + w_txt × p_txt        (con w_img + w_txt = 1)
```

En el promedio simple los dos pesos son 0.5. La pregunta interesante es: **¿y si los pesos cambiaran según qué tan segura está cada modalidad en cada película?** Esa es la idea de nuestro método (sección 11).

- **Ventaja:** podemos ver qué opina cada modalidad por separado, y eso permite diagnosticar quién domina.
- **Problema:** no aprende relaciones finas entre imagen y texto, porque cada red trabaja sola.

5.3 Fusión intermedia: mezclar a mitad de camino

Cada modalidad pasa primero por su propia red un rato, y luego las fichas intermedias se mezclan antes de la decisión final. Un ejemplo famoso es la **GMU**, que tiene una "perilla" aprendida que decide en cada película cuánto pesa cada modalidad. Se propuso junto con el dataset MM-IMDB.

5.4 Las tres formas comparadas

Forma	Cuándo se juntan	Analogía	Rol en el proyecto
Temprana (concatenar)	Al principio	Un juez lee los dos informes juntos	Modelo ingenuo (el que tiene el problema)
Tardía (promediar)	Al final	Dos jueces opinan por separado y se promedian sus votos	Base de nuestro método
Intermedia (GMU)	A mitad de camino	Dos jueces se reúnen antes de votar	Referencia histórica

6. Paso 3 — Predecir varios géneros a la vez

Como una película puede tener varios géneros, el modelo responde 23 preguntas de sí o no por separado: ¿es de Terror?, ¿es Drama?, ¿es Comedia?, etc. A esto se le llama clasificación **multietiqueta**.

6.1 Del puntaje a la probabilidad: la sigmoide

Para cada género, la red produce un **puntaje**: un número cualquiera, positivo o negativo. Un puntaje alto significa "creo que sí" y uno muy negativo "creo que no". Para convertirlo en una probabilidad entre 0 y 1 se usa la función **sigmoide** (σ):

Puntaje	Probabilidad σ(puntaje)	Se lee
−4	0.02	Casi seguro que no
−2	0.12	Probablemente no
0	0.50	No sé
2	0.88	Probablemente sí
4	0.98	Casi seguro que sí

La fórmula es σ(puntaje) = 1 / (1 + e^(−puntaje)), pero lo importante es la tabla: puntajes grandes dan probabilidades cercanas a 1 y puntajes muy negativos dan probabilidades cercanas a 0.

¿Por qué no se usa softmax? Softmax obliga a que las probabilidades de todos los géneros sumen 1, como si la película solo pudiera tener uno. Con la sigmoide, cada género tiene su probabilidad propia: Terror puede tener 0.85 y Drama 0.70 al mismo tiempo.

6.2 De la probabilidad al sí o no: el umbral

Para decidir, se compara cada probabilidad con un **umbral**. Si la supera, la respuesta es "sí".

Ejemplo con *La casa del silencio* (umbral 0.5):

Género	Probabilidad	¿Supera 0.5?	Respuesta	¿Lo tiene de verdad? / Resultado
Terror	0.85	Sí	Sí	Sí ✅
Drama	0.40	No	No	Sí ❌ (se escapó)
Comedia	0.05	No	No	No ✅
Misterio	0.55	Sí	Sí	No ❌ (falsa alarma)

El umbral no tiene por qué ser 0.5. Para géneros raros, como Film-Noir (≈1% de las películas), la red casi nunca da probabilidades altas y conviene un umbral más bajo, por ejemplo 0.2. El umbral de cada género se elige probando valores en los datos de **validación**, nunca en los de prueba. Si se eligiera mirando los datos de prueba, estaríamos haciendo trampa sin darnos cuenta (a esto se le llama **fuga de datos**).

6.3 Los tres grupos de datos

Grupo	Para qué se usa	Analogía
Entrenamiento	La red aprende con estos ejemplos	Los ejercicios que estudias
Validación	Elegir umbrales y ajustes, y decidir cuándo parar	El simulacro antes del examen
Prueba	Medir el resultado final, una sola vez	El examen real: no se mira antes

7. Paso 4 — Cómo aprende el modelo

Aprender es repetir muchas veces tres pasos: adivinar, medir qué tan mal se adivinó y ajustar un poquito para adivinar mejor la próxima vez.

7.1 Medir el error: la pérdida

La **pérdida** es un número que dice qué tan equivocada fue una predicción. Cero es perfecto, y mientras más grande, peor. Para preguntas de sí o no se usa la **entropía cruzada binaria**, cuya idea es:

- Si la respuesta correcta es "sí", la pérdida es −log(probabilidad que diste al "sí").
- Si la respuesta correcta es "no", la pérdida es −log(probabilidad que diste al "no").

Ejemplo: *La casa del silencio* sí es de Terror.

Lo que dijo el modelo	Pérdida	Interpretación
90% Terror	−log(0.90) = 0.11	Acertó con confianza: casi sin castigo
50% Terror	−log(0.50) = 0.69	Dudó: castigo medio
20% Terror	−log(0.20) = 1.61	Se equivocó: castigo grande
1% Terror	−log(0.01) = 4.61	Se equivocó muy seguro: castigo enorme

La última fila es la clave: **equivocarse con mucha seguridad se castiga muchísimo más que equivocarse dudando.** Por eso esta pérdida empuja al modelo a dar probabilidades honestas.

La pérdida total es el promedio sobre los 23 géneros y sobre todas las películas.

7.2 Ajustar: el descenso por gradiente

La red tiene miles de perillas internas (sus **pesos**). El **gradiente** dice, para cada perilla, hacia dónde girarla para que la pérdida baje. En cada paso, cada perilla se gira un poquito en esa dirección.

Analogía: estás en una montaña con niebla y quieres bajar al valle. No ves el valle, pero sientes hacia dónde se inclina el suelo bajo tus pies. Das un paso en esa dirección y repites. El valle es el punto de menor pérdida.

7.3 El ciclo completo

1. Tomar un grupo de películas (un **lote**, por ejemplo 64).
2. Calcular las probabilidades de los 23 géneros para cada una.
3. Calcular la pérdida comparando con los géneros verdaderos.
4. Calcular el gradiente y girar las perillas un poquito.
5. Repetir con el siguiente lote. Una pasada por todas las películas de entrenamiento se llama **época**.

Con los encoders congelados, las únicas perillas que se giran son las de las redes pequeñas que van después de las fichas (las **cabezas**). CLIP no cambia.

7.4 ¿Cuándo parar?

Después de cada época se mide el resultado en los datos de validación. Al principio mejora; en algún momento la red empieza a memorizar los ejemplos de entrenamiento en vez de aprender patrones generales (**sobreajuste**) y el resultado en validación empeora. Ahí se para y se guarda la mejor versión. A esto se le llama **parada temprana**.

7.5 La semilla

El entrenamiento tiene azar: los pesos iniciales y el orden de las películas son aleatorios. La **semilla** es el número que fija ese azar para poder repetir el experimento exactamente. En el proyecto cada experimento se corre con 5 semillas distintas y se reporta el promedio con su intervalo de confianza, para mostrar que el resultado no fue suerte.

8. Paso 5 — Cómo medir si funciona

La métrica principal del proyecto es el **F1 macro**. Para entenderla hay que pasar por tres ideas: precisión, cobertura y F1.

8.1 Precisión y cobertura, con un ejemplo

En los datos de prueba hay 10 películas que de verdad son de Terror. El modelo marca 8 películas como Terror, y de esas 8, 6 lo son de verdad.

Medida	Pregunta que responde	Cuenta	Valor
Precisión	De las que marcó como Terror, ¿cuántas lo eran?	6 de 8	0.75
Cobertura (recall)	De las que eran de Terror, ¿cuántas encontró?	6 de 10	0.60

Las dos importan y compiten entre sí:

- Un modelo que marca **todo** como Terror encuentra las 10 (cobertura 1.0), pero se equivoca muchísimo (precisión baja).
- Un modelo que marca **solo** la película más obvia acierta (precisión 1.0), pero se le escapan 9 (cobertura 0.1).

8.2 F1: un solo número que combina ambas

El **F1** junta precisión y cobertura en un solo número, y solo es alto si **ambas** son altas:

```
F1 = 2 × precisión × cobertura / (precisión + cobertura)
```

En el ejemplo: F1 = 2 × 0.75 × 0.60 / (0.75 + 0.60) = 0.90 / 1.35 = **0.67**.

8.3 Macro y micro: cómo juntar los 23 géneros

Tenemos un F1 por género, pero queremos un solo número para todo el modelo. Hay dos formas comunes de juntarlos.

Ejemplo con 3 géneros:

Género	Películas de ese género	F1
Drama	500 (muy común)	0.80
Terror	100	0.67
Film-Noir	10 (muy raro)	0.20

- **F1 macro:** promedio simple de los F1 de cada género. (0.80 + 0.67 + 0.20) / 3 = **0.56**. Cada género pesa igual, así que fallar en Film-Noir baja mucho el resultado.

- **F1 micro:** se suman los aciertos y errores de todos los géneros y se calcula un solo F1. Como Drama tiene muchas más películas, domina el resultado, que quedaría cerca de 0.77. Fallar en Film-Noir casi no se nota.

¿Por qué elegimos el macro? Porque el proyecto trata de no ignorar señales débiles. Un modelo que solo aprende los géneros fáciles y comunes puede verse bien en micro y mal en macro. Igual reportamos ambos, porque es lo que hace la literatura de MM-IMDB.

8.4 El resultado siempre con su margen de error

Un F1 de 0.56 solo no basta: puede haber salido así por suerte. Por eso se corre cada experimento con 5 semillas y se reporta, por ejemplo, **F1 macro = 0.56 ± 0.01**, que se lee "el promedio es 0.56 y con 95% de confianza el valor verdadero está entre 0.55 y 0.57". Si dos métodos tienen intervalos que se traslapan mucho, no se puede afirmar que uno sea mejor.

9. El clasificador de Bayes: el mejor resultado posible

El clasificador de Bayes es la regla "apuesta siempre por lo más probable, conociendo las probabilidades verdaderas". Ningún modelo puede acertar más que él con la misma información, así que funciona como el techo de cualquier método.

9.1 Ejemplo solo con la sinopsis

Imagina que existen exactamente 100 películas con la sinopsis "una familia se muda a una casa donde pasan cosas extrañas", y un oráculo sabe su género real: 65 son de Terror, 25 de Drama y 10 de Comedia. Te muestran una al azar y debes adivinar.

Estrategia	Aciertos
Decir siempre **Terror** (lo más probable)	**65%**
Decir siempre Drama	25%
Decir siempre Comedia	10%
Elegir al azar respetando las proporciones	≈ 49.5%

La mejor estrategia es apostar por lo más probable: **esa regla es el clasificador de Bayes.** Aun así, se equivoca el 35% de las veces. Ese 35% es el **error de Bayes**: no es culpa del modelo, sino de que la sinopsis sola no alcanza para distinguir esas películas.

9.2 El mismo ejemplo agregando el póster

Ahora el oráculo separa esas mismas 100 películas según su póster:

Póster	Terror	Drama	Comedia	Mejor apuesta	Aciertos
Oscuro (60 películas)	58	2	0	Terror	58
Colorido (40 películas)	7	23	10	Drama	23
Total	65	25	10		**81 de 100**

Con la misma regla, pero mirando sinopsis **y** póster, se acierta 81 de 100. El error de Bayes bajó del 35% al 19%: el póster aportó información que la sinopsis no tenía.

9.3 Qué nos dice esto para el proyecto

- **Agregar una modalidad nunca empeora el mejor resultado posible**, y lo mejora si trae información nueva.
- Si con ambas el techo es 81%, pero nuestro modelo multimodal solo logra 65% (lo mismo que con el texto solo), el modelo **desperdició información que sí estaba ahí**. Esa diferencia es lo que el proyecto quiere medir.
- En la vida real no hay oráculo: nunca conocemos esas proporciones verdaderas. Una red neuronal intenta **estimarlas** con los datos, como cuando en estadística estimas una proporción con una muestra. Si la red dice "65% Terror", está dando su estimación de esa proporción.

La cantidad de información nueva que trae el póster cuando ya tienes la sinopsis tiene un nombre técnico: **información mutua condicional**. Si vale cero, el póster no ayuda; si es mayor que cero, existe una mejora posible.

10. El problema: la modalidad glotona (greedy modality)

Muchas veces el modelo multimodal termina usando casi solo una modalidad, la más fácil, y casi ignora la otra. Entonces rinde igual que el mejor modelo de una sola modalidad, y la segunda modalidad no sirvió de nada.

10.1 La analogía de los dos libros

Tienes un examen y dos libros: uno fácil (la sinopsis) y uno difícil (el póster). Empiezas con el fácil, y como con él ya respondes bien la mayoría de preguntas, nunca abres el difícil. Sacas buena nota, pero no la mejor posible: había preguntas que solo el libro difícil respondía.

10.2 Por qué pasa, paso a paso

Recuerda que el modelo aprende corrigiendo sus errores (sección 7). En la fusión, ambas modalidades reciben la misma corrección, que depende del **error de la respuesta conjunta**.

Momento	Rama de texto	Rama de imagen	Error conjunto	Qué aprende la imagen
Inicio	No sabe nada	No sabe nada	Grande	Recibe corrección y aprende un poco
Época 2	Ya acierta bastante (el texto es fácil)	Todavía acierta poco	Mediano	Recibe menos corrección
Época 5	Acierta casi todo lo que puede	Sigue débil	Pequeño	Casi no recibe corrección: deja de aprender

La clave está en la última fila: el texto ya hizo bajar el error conjunto, así que la imagen deja de recibir señal para mejorar, **aunque ella sola todavía sea mala**. La modalidad fuerte "le apaga" el aprendizaje a la débil.

10.3 Cómo se ve en los resultados

Modelo	F1 macro (ejemplo ilustrativo)
Solo póster	0.35
Solo sinopsis	0.55
Fusión ingenua (concatenar)	0.56
Techo teórico (lo que se podría lograr)	más alto

La fusión apenas supera al texto solo. Esa diferencia tan pequeña es la señal del problema. Estos números son inventados para ilustrar; los reales los obtendremos en el primer experimento.

10.4 Las soluciones que ya existen

- **OGM-GE** (2022): durante el entrenamiento mide qué modalidad va ganando y le baja el volumen a su corrección, para que la débil tenga oportunidad de aprender. Es como obligarte a estudiar menos del libro fácil.

- **PMR** (2023): le da a la modalidad débil una tarea extra que solo depende de ella (acercar cada película al "centro" de su género), para que aprenda sin depender de la otra.

Ambas funcionan, pero son reglas de ingeniería: no explican cuánto se pierde ni por qué. Nuestro proyecto quiere medirlo con estadística y corregirlo con una idea más directa (sección 11).

11. Confianza, calibración y la idea de nuestro método

Nuestro método combina las modalidades dándole más peso, en cada película, a la que está menos insegura. Para que eso funcione, la seguridad que declara cada modalidad tiene que ser honesta; a eso se le llama estar **calibrada**.

11.1 ¿Qué es estar calibrado?

Un modelo está calibrado si, cuando dice "80% seguro", acierta más o menos el 80% de esas veces. Es como un meteorólogo: si anuncia 80% de lluvia en 100 días distintos, debería llover en unos 80 de ellos.

Ejemplo: juntamos las 100 veces en que el modelo dijo "90% seguro".

Si de esas 100 acertó…	Diagnóstico
90	Calibrado: su confianza es honesta
70	**Sobreconfiado:** dice estar más seguro de lo que debería
98	**Subconfiado:** está más seguro de lo que admite

El **ECE** (error de calibración esperado) resume esto en un número: el promedio de la distancia entre la confianza declarada y el acierto real. En el caso sobreconfiado de la tabla, esa distancia es 0.90 − 0.70 = 0.20. Un ECE de 0 es calibración perfecta.

11.2 Por qué importa en lo multimodal

Nuestra sospecha (que vamos a comprobar con datos) es que la modalidad fuerte se vuelve **sobreconfiada** y la débil **subconfiada**. Si la fusión le cree a la confianza de cada una, le dará demasiado peso a la fuerte y repetirá el problema de la modalidad glotona.

11.3 Medir la inseguridad de una predicción

Para un género, una probabilidad cercana a 0 o a 1 es una predicción segura, y una cercana a 0.5 es insegura. La **entropía** convierte eso en un número de inseguridad:

Probabilidad de Terror	Inseguridad (entropía)	Se lee
0.50	0.69 (la máxima)	No tengo idea
0.70	0.61	Algo inseguro
0.90	0.33	Bastante seguro
0.99	0.06	Muy seguro

11.4 Nuestro método, con números

La regla es dar a cada modalidad un peso inversamente proporcional a su inseguridad: menos inseguridad, más peso.

Película A (la sinopsis es clara y el póster ambiguo):

	Probabilidad de Terror	Inseguridad	1 / inseguridad	Peso
Póster	0.60	0.67	1.5	1.5 / 4.5 = **0.33**
Sinopsis	0.90	0.33	3.0	3.0 / 4.5 = **0.67**

Resultado: 0.33 × 0.60 + 0.67 × 0.90 = **0.80**. Aquí manda la sinopsis, como debe ser.

Película B (la sinopsis es vaga, "una historia sobre una familia", y el póster es muy claro: una figura fantasmal):

	Probabilidad de Terror	Inseguridad	1 / inseguridad	Peso
Póster	0.95	0.20	5.0	5.0 / 6.5 = **0.77**
Sinopsis	0.55	0.69	1.5	1.5 / 6.5 = **0.23**

Resultado: 0.77 × 0.95 + 0.23 × 0.55 = **0.86**. Aquí manda el póster. Un promedio fijo de 50/50 habría dado 0.75 y habría subvalorado la evidencia clara de la imagen.

La idea central: el peso de cada modalidad no es fijo, cambia película por película según quién tiene más información en ese caso. Así la modalidad débil no se ignora siempre: se escucha justo cuando tiene algo claro que decir.

La condición para que funcione: las inseguridades deben ser honestas (calibradas). Si el texto está sobreconfiado, siempre parecerá seguro y siempre ganará. Por eso el proyecto mide y corrige la calibración de cada modalidad antes de combinarlas.

12. Resumen y glosario rápido

12.1 Todo el recorrido en una tabla

Paso	Qué entra	Qué sale	Quién lo hace	¿Se entrena?
1. Convertir en números	Póster y sinopsis	Dos fichas de 512 números (z_img, z_txt)	CLIP (encoders)	No, está congelado
2. Combinar	Las dos fichas	Una ficha combinada, o dos opiniones	Fusión	Depende del método
3. Predecir	Ficha u opiniones	23 probabilidades → 23 sí/no	Cabeza + sigmoide + umbral	Sí (la cabeza)
4. Aprender	Probabilidades y géneros reales	Perillas ajustadas	Pérdida + gradiente	—
5. Medir	Predicciones de prueba	F1 macro ± margen, ECE	Métricas	—

12.2 Glosario

Término	Definición corta
Atención	Mecanismo por el que cada pedazo (parche o palabra) actualiza su significado mirando a los demás
Cabeza	Red pequeña que va después del encoder y aprende la tarea; es lo único que entrenamos
Calibración	Que la confianza declarada coincida con el acierto real
CLIP	Par de encoders (imagen y texto) entrenados para que una foto y su descripción den fichas parecidas

Término	Definición corta
Concatenar	Pegar dos listas de números una detrás de la otra
Congelar	Usar un modelo sin cambiar sus pesos
ECE	Número que mide qué tan mal calibrado está un modelo (0 es perfecto)
Embedding	Lista de números que describe un dato; datos parecidos dan listas parecidas
Encoder	Programa que convierte un dato crudo en un embedding
Entropía	Número que mide la inseguridad de una predicción
Época	Una pasada completa por todos los datos de entrenamiento
Error de Bayes	El error que ni el mejor modelo posible puede evitar con la información disponible
F1	Número que combina precisión y cobertura
Fuga de datos	Usar sin querer información de la prueba durante el entrenamiento o los ajustes
Fusión	Paso donde se combinan las modalidades
Gradiente	Indica hacia dónde ajustar cada peso para que baje la pérdida
Greedy modality	Cuando una modalidad domina el aprendizaje y la otra queda ignorada
Lote	Grupo de ejemplos que se procesan juntos en un paso
Modalidad	Un tipo de información: imagen, texto, audio, etc.
Multietiqueta	Cada ejemplo puede tener varias etiquetas a la vez
Parche	Cuadrito de la imagen (32 × 32 píxeles) que el ViT trata como una "palabra visual"
Pérdida	Número que mide qué tan mal predijo el modelo
Semilla	Número que fija el azar para poder repetir un experimento

Término	Definición corta
Sigmoide	Función que convierte un puntaje en una probabilidad entre 0 y 1
Sobreajuste	Cuando el modelo memoriza el entrenamiento y falla con datos nuevos
Token	Pedacito de texto (una palabra o parte de ella)
Umbral	Valor que debe superar una probabilidad para responder "sí"
ViT	Vision Transformer: el tipo de red que usa CLIP para leer imágenes